

LAPORAN TEKNIS KOMPREHENSIF

Coding Camp 2026 powered by DBS Foundation

Tema	Sustainable Living & Responsible Consumption
Topik	Deteksi Headline Hoaks & Clickbait berbasis NLP
Path	Data Science
ID Tim	CC26-PSU395
Periode	15 April – 31 Mei 2026

Nama	Role	ID
Alvin Grand Putra	Full-Stack Web Developer	CFCC133D6Y0276
Yayan Rif'an Awaludin	Full-Stack Web Developer	CFCC007D6Y1819
Johana Oktavia Ramadhani	Data Scientist	CDCC007D6X2684
Desvita Maharani	Data Scientist	CDCC007D6X2681
Anugrah Syahputra Sibarani	AI Engineer	CACC319D6Y2551
Raden Fitzal Bintang Nugraha Wiradikoesoema	AI Engineer	CACC001D6Y0549

DAFTAR ISI

COVER	1
DAFTAR ISI	2
1. Ringkasan Eksekutif	3
2. Problem Discovery	4
3. Arsitektur Sistem & Pipeline	5
4. Data Wrangling	5
4.1 Dataset 1 - Clickbait vs Non-Clickbait.....	6
4.2 Dataset 2 - Stance Detection.....	7
4.3 Dataset 3 - Dewan Pers (Trusted Domain).....	9
4.4 Dataset 4 - Hoax vs Valid.....	10
4.5 Data Dictionary.....	11
4.6 Ringkasan seluruh Dataset.....	13
5. Exploratory Data Analysis (EDA)	13
5.1 EDA Clickbait.....	13
5.2 EDA Stance Detection.....	15
5.3 EDA Hoax vs Valid.....	17
6. Feature Engineering	18
7. A/B Testing & Eksperimen	19
8. Dashboard Streamlit & Deployment	20
9. Kesimpulan & Rekomendasi	21
9.1 Kesimpulan.....	21
9.2 Rekomendasi.....	22

1. Ringkasan Eksekutif

Laporan ini mendokumentasikan seluruh proses kerja tim Data Science pada Capstone Project Coding Camp 2026 powered by DBS Foundation, mulai dari identifikasi masalah, pengumpulan dan pembersihan data, eksplorasi data, rekayasa fitur, hingga A/B Testing dan deployment dashboard.

Penyebaran hoaks dan clickbait di era digital menjadi tantangan serius. Reuters Institute Digital News Report 2025 menunjukkan 44% pengguna usia 18-24 tahun menjadikan media sosial sebagai sumber berita utama dengan pola scanning cepat tanpa verifikasi. Studi MIT menunjukkan berita palsu menyebar 6× lebih cepat dan 70% lebih sering dibagikan dibanding berita valid.

Sebagai solusi, tim membangun sistem NLP berbasis pipeline bertahap yang memproses headline berita secara real-time: Sistem melakukan scraping artikel terkait, lalu menjalankan empat analisis paralel, deteksi clickbait, deteksi stance, verifikasi sumber terpercaya, menghitung cosine similarity antara headline dengan artikel terkait, kemudian melakukan perhitungan persentase hoax. Keempat komponen ini masing-masing dilatih dari dataset yang berbeda.

Tabel berikut merangkum komponen sistem, dataset yang digunakan, serta output yang dihasilkan oleh masing-masing komponen:

Komponen Sistem	Data Final	Output
Deteksi Clickbait (clickbait.csv)	14.719 data	Clickbait → eliminasi / Non-Clickbait → lanjut
Deteksi Stance (dataset_stance.csv)	300 data	Mendukung / Membantah
Trusted Domain (dewan_pers.csv)	875 media	Terverifikasi / Tidak
Hoax Scoring (hoax-fake.csv)	1.042 data	% kemungkinan hoax

Github Repository	https://github.com/JohanaOktaviaRamadhani/headline-hoax-detector
Streamlit Dashboard	https://headline-hoax-detector-team.streamlit.app/

2. Problem Discovery

Problem Statement: Bagaimana membangun sistem NLP yang mampu menganalisis kredibilitas headline berita berbahasa Indonesia secara real-time melalui pipeline bertahap - deteksi clickbait, analisis stance, verifikasi domain, dan hoax scoring - untuk mendukung konsumsi informasi yang lebih bertanggung jawab?

Pertanyaan Bisnis yang Terukur

Untuk memastikan setiap komponen sistem menjawab kebutuhan yang konkret, ditetapkan lima pertanyaan bisnis berikut yang menjadi acuan evaluasi keberhasilan proyek:

- 1) Apakah artikel-artikel terkait menggunakan judul yang menyesatkan (clickbait)?
- 2) Dari artikel yang lolos filter clickbait, apakah lebih banyak yang mendukung atau membantah headline yang diuji?
- 3) Apakah domain sumber artikel termasuk media terpercaya berdasarkan verifikasi Dewan Pers?
- 4) Berapa persentase kemungkinan headline ini adalah hoax berdasarkan agregasi stance, similarity, dan kredibilitas sumber?

Tujuan	Metrik	Target
Deteksi clickbait akurat	Accuracy & F1-Score	$\geq 85\%$ / ≥ 0.80
Deteksi stance mendukung/membantah	Accuracy & F1-Score	$\geq 80\%$
Verifikasi 875 domain terpercaya	Coverage Dewan Pers	100%
Hoax scoring proporsional	Relevansi skor	Skor mencerminkan agregasi artikel
Dashboard EDA live & publik	Streamlit deployed Cloud	Link dapat diakses

3. Arsitektur Sistem & Pipeline

Sistem bekerja sebagai pipeline bertahap dengan percabangan. Setelah scraping, setiap artikel dicek apakah termasuk clickbait. Artikel yang terdeteksi clickbait langsung dieliminasi dan tidak diproses lebih lanjut. Hanya artikel non-clickbait yang melanjutkan ke analisis stance, verifikasi domain, perhitungan similarity, dan perhitungan skor hoax.

Tabel berikut menjabarkan setiap tahap beserta input, output, dan metode yang digunakan:

Tahap	Proses	Dataset / Metode	Output
1	User input headline	-	Query pencarian
2	Scraping artikel	Web scraper	title, source, url, tgl, isi, snippet
3	Deteksi Clickbait	clickbait.csv + model ML	Clickbait → langsung dieliminasi
4	Deteksi Stance (<i>non-clickbait saja</i>)	dataset_stance.csv + kamus sentimen	Mendukung / Membantah
5	Trusted Domain Check	dewan_pers.csv (875 media)	Terverifikasi / Tidak
6	Cosine Similarity	Kemiripan artikel vs headline input	Skor kemiripan
7	Hoax Probability Scoring	Agregasi 4 fitur berbobot	Persentase kemungkinan hoax
8	Output final	Semua hasil	Tabel : Judul, sumber, status stance, % similarity dan % hoax

Catatan: Semakin banyak artikel Membantah dengan similarity tinggi dari sumber terpercaya → semakin tinggi kemungkinan hoax. Kalkulasi akhir berdasarkan proporsi artikel Membantah yang lolos filter clickbait dan berasal dari domain terpercaya, dibandingkan dengan total artikel

4. Data Wrangling

Keempat dataset diproses secara independen menggunakan Python (Pandas, Sastrawi, langdetect) di Google Colab. Urutan pembahasan

mengikuti alur pipeline sistem: Clickbait → Stance → Dewan Pers → % similarity → Hoax. Stopwords yang digunakan pada dataset yang memerlukannya: gabungan Sastrawi + lokal = **381 kata**.

4.1 Dataset 1 - Clickbait vs Non-Clickbait

Dataset ini berisi artikel berita berbahasa Indonesia yang digunakan untuk melatih model deteksi clickbait (Tahap 3 pipeline). Dataset bersumber dari kumpulan berita yang sudah dilabeli secara manual sebagai clickbait atau non-clickbait.

Sumber file	clickbait.csv
Kolom raw	headline, article, label, source, date, url (6 kolom)
Kolom output	clean_text (full_text), label_text
File output	final_clickbait.csv

Tabel berikut merangkum informasi dasar dataset sebelum proses cleaning dimulai:

No	Tahap	Detail	Data Tersisa
1	Load data	15.288 baris, 6 kolom	15.288
2	Cek & drop null	49 null pada kolom article → drop	15.239
3	Cek & drop duplikat	436 duplikat → drop	14.803
4	Seleksi kolom	Pertahankan: headline, article, label	3 kolom
5	Mapping label	'clickbait'→1, 'non-clickbait'→0	14.803
6	Normalisasi teks	Lowercase, hapus URL/mention/ simbol/ angka tanda baca, serta merapikan spasi ganda	14.803
7	Buat full_text	headline + ' ' + article	14.803
8	Drop duplikat pasca gabung	7 duplikat → drop	14.796

9	Formalisasi 7 slang	7 kata (yg, tdk, dgn, hoax, bkn, tp, klo)	14.796
10	Hitung article_len	len(full_text.split()) - mean 259 kata, max 3.027	14.796
11	Filter panjang	10–1.000 kata	14.728
12	Deteksi bahasa	Sampling 1.000 (99.7% id) → filter 'id'	14.719 final

Label	Jumlah	Persentase
non-clickbait (0)	8.613	58.5%
clickbait (1)	6.106	41.5%
Total	14.719	100%

Catatan: Distribusi relatif seimbang (58.5% vs 41.5%) - tidak memerlukan teknik balancing agresif. Dataset terbesar dalam pipeline memberikan fondasi statistik yang kuat untuk model.

4.2 Dataset 2 - Stance Detection

Dataset stance berasal dari platform Kompasiana dan digunakan untuk melatih model analisis stance (Tahap 4 pipeline) hanya aktif untuk artikel non-clickbait. Topiknya spesifik pada isu Ahok, dengan preprocessing paling kompleks karena melibatkan stemming Sastrawi dan feature engineering sentimen.

Sumber file	dataset_stance.csv
Kolom raw	no, _id, topic, title, content, stance, source, nnps (8 kolom)
Kolom output	clean_text, label, pos_count, neg_count, sentiment_score
File output	final_data_stance.csv

No	Tahap	Detail	Data Tersisa
1	Load data	dataset_stance.csv - 402 baris, 8 kolom	402 baris

2	Drop kolom	Hapus: no, _id, topic, nnps	402 baris
3	Konversi content	String-list → plain text via ast.literal_eval	402 baris
4	Gabung teks	text = title + ' ' + content	402 baris
5	Hapus 'unknown'	102 data berlabel unknown dihapus	300 data
6	Mapping label	'for'→Mendukung, 'against'→Membantah	Label Indonesia
7	Normalisasi teks	Lowercase, hapus URL, mention, hashtag, angka, simbol, dan normalisasi spasi.	Teks bersih
8	Formalisasi 10 slang	10 kata (yg, tdk, dgn, hoax, bkn, tp, klo, ga/gak, udah)	0 slang tersisa
9	Remove stopwords	381 stopwords; kata sentimen DILINDUNGI	Teks ringkas
10	Stemming Sastrawi	Setiap kata ke bentuk dasar	clean_text
11	Hitung text_length	len(clean_text.split()) — mean 433, median 352	300
12	Feature engineering	pos_count, neg_count, sentiment_score	Fitur sentimen
13	Label encoding	Membantah=0, Mendukung=1	300 data final

Label	Jumlah	Persentase	Encoding
Mendukung (1)	177	59.0%	1
Membantah (0)	123	41.0%	0
Total	300	100%	-

Catatan: Dataset terkecil hanya 300 data. Kata negasi (tidak, bukan, tanpa, belum, kurang) dan seluruh kamus sentimen

positif/negatif dilindungi dari penghapusan stopwords karena menjadi fitur kunci pembeda stance.

4.3 Dataset 3 - Dewan Pers (Trusted Domain)

Dataset ini bukan untuk training model, melainkan sebagai whitelist domain terpercaya untuk Tahap 5 pipeline. Data bersumber dari scraping situs resmi Dewan Pers Indonesia. Domain artikel scraping dicocokkan dengan daftar ini secara langsung tanpa model ML.

Sumber file	dewan_pers.csv - scraping dari https://datapers.dewanpers.or.id/site/iframe-verified
Kolom raw	12 kolom: nama_media, jenis_media, status, website, dll
Kolom output	nama_media, website
File output	final-pers.csv

No	Filter	Kondisi	Hasil
1	Load data	2.640 baris, 12 kolom	2.640 media
2	Filter jenis media	jenis_media == 'Siber' (hanya media online)	1.295
3	Filter status verifikasi	status == 'Terverifikasi Administratif dan Faktual'	933 media
4	Seleksi kolom	Pertahankan: nama_media, website saja	2 kolom
5	Drop null website	58 baris tanpa website → drop	875 media
6	Drop duplikat	0 duplikat	875 data final

Catatan: Dari 2.640 total media, hanya 875 (33.1%) yang memenuhi kriteria Siber + Terverifikasi penuh. Ada 4 nilai unik status di data Siber hanya yang persis 'Terverifikasi Administratif dan Faktual' yang diambil. Tidak ada normalisasi teks karena fungsinya murni domain matching.

4.4 Dataset 4 - Hoax vs Valid

Dataset ini disediakan sebagai referensi konteks untuk memahami karakteristik artikel hoax vs valid secara linguistik. Perlu dicatat bahwa dataset ini tidak langsung digunakan dalam formula perhitungan Hoax Probability Score, scoring dilakukan berdasarkan akumulasi keempat fitur pipeline (Clickbait, Stance, Trusted Domain, Similarity). Dataset berisi artikel berita berbahasa Indonesia yang sudah diverifikasi status kebenarannya.

Sumber file	hoax-fake.csv
Kolom raw	Label, Headline, Body, Unnamed:3-6 (7 kolom — 4 Unnamed seluruhnya null)
Kolom output	clean_text (full_text), label_text
File output	final-data-hoax.csv

No	Tahap	Detail	Hasil
1	Load data	1.116 baris, 7 kolom	1.116 baris
2	Drop kolom null	Seluruhnya null (1.116 null tiap kolom)	3 kolom
3	Drop duplikat	1 duplikat dihapus	1.115 baris
4	Seleksi kolom	Pertahankan: Headline, Body, Label	1.115 baris
5	Mapping label	Label 1→'valid', 0→'hoax' (string)	1.115 baris
6	Rename kolom	Headline→headline, Body→article	1.115 baris
7	Normalisasi teks	Lowercase, hapus URL/mention/hashtag/simbol/angka	1.115 baris
8	Buat full_text	headline + ' ' + article	1.115 baris
9	Drop duplikat pasca gabung	2 duplikat → drop	1.113 baris

10	Formalisasi slang	yg, tdk, dgn, hoax, bkn, tp, klo	0 slang tersisa
11	Stopword Removal	Membuang kata-kata umum menggunakan Sastrawi & kustom stopwords	-
12	Hitung article_len	mean 393 kata, max 4.403 kata (sebelum filter)	1.113
13	Filter panjang	10-1.000 kata	1.056
14	Deteksi bahasa	Sampling 1.000 (98.8% id) → filter 'id'	1.042
15	Label encoding	hoax=0, valid=1	1.043 data final

Label	Sebelum Filter	Setelah Filter (Final)	Persentase
hoax (0)	683	643	61.7%
valid (1)	432	399	38.3%
Total	1.115	1.042	100%

Catatan: Dataset imbalanced (61.7% hoax). Tidak ada stopwords removal pada full_text - stopwords hanya dipakai di CountVectorizer untuk visualisasi EDA top words. Statistik panjang artikel setelah filter: mean 321 kata, median 300 kata, max 986 kata.

4.5 Data Dictionary

Berikut dokumentasi lengkap kolom pada masing-masing file final yang diserahkan untuk tahap pemodelan.

1) Dataset Clickbait - final_clickbait.csv

Kolom	Tipe	Deskripsi	Contoh Nilai
clean_text	string	Gabungan headline + article setelah normalisasi lengkap dan formalisasi slang	'viral driver ojol bekasi antar pesanan...'

label_text	integer	Kelas target: 0 = Non-Clickbait, 1 = Clickbait	0 atau 1
------------	---------	--	----------

2) Dataset Stance - final_data_stance.csv

Kolom	Tipe	Deskripsi	Contoh Nilai
clean_text	string	Teks setelah normalisasi, stopword removal, dan stemming Sastrawi	'sungguh benci ahok prestasi saing...'
label	integer	Kelas stance: 0 = Membantah, 1 = Mendukung	0 atau 1
pos_count	integer	Jumlah kata positif dalam clean_text berdasarkan kamus positif-indonesia.txt	8
neg_count	integer	Jumlah kata negatif dalam clean_text berdasarkan kamus negatif-indonesia.txt	9
sentiment_score	integer	Skor sentimen bersih: pos_count – neg_count	-1

3) Dataset Dewan Pers - final-pers.csv

Kolom	Tipe	Deskripsi	Contoh Nilai
nama_media	string	Nama resmi media yang terverifikasi Dewan Pers Indonesia	'Akurat.co'
website	string	URL website media - digunakan sebagai kunci domain matching saat artikel scraping masuk	'https://akurat.co/'

4) Dataset Hoax & Fake - final-data-hoax.csv

Kolom	Tipe	Deskripsi	Contoh Nilai
clean_text	string	Gabungan headline + article setelah normalisasi lengkap dan formalisasi	'pertamina pemerintah klarifikasi isu

		slang digunakan sebagai referensi Cosine Similarity	bbm...'
label_text	integer	Kelas target: 0 = Hoax, 1 = Valid/Fakta	0 atau 1

4.6 Ringkasan seluruh Dataset

Tabel berikut merangkum kondisi akhir keempat dataset setelah seluruh proses wrangling selesai. Penurunan dari raw ke final disebabkan oleh filter null, duplikat, panjang artikel, dan bahasa.



Dataset	File Raw	File Final	Label Encoding	Kolom Final
Clickbait	clickbait.csv 15.288 baris	final_clickbait.csv 14.719 baris	non-cb=0, clickbait=1	clean_text, label_text
Stance	dataset_stance.csv 402 baris	final_data_stance.csv 300 baris	Membantah=0, Mendukung=1	clean_text, label, pos_count, neg_count, sentiment_score
Dewan Pers	dewan_pers.csv 2.640 baris	final_pers.csv 875 baris	-	nama_media, website
Hoax vs Valid	hoax_fake.csv 1.116	final_data_hoax.csv 1.042	hoax=0, valid=1	clean_text, label_text

5. Exploratory Data Analysis (EDA)



EDA dilakukan per dataset menggunakan Matplotlib & Seaborn. Seluruh visualisasi berikut diambil langsung dari output notebook masing-masing, beserta narasi interpretasi yang telah disusun.

5.1 EDA Clickbait



Dataset akhir: 14.719 artikel dengan distribusi Non-Clickbait 58.5% (8.613) dan Clickbait 41.5% (6.106). Rata-rata panjang artikel: 256 kata (non-clickbait: 263 kata, clickbait: 246 kata).



Distribusi label menunjukkan kelas non-clickbait lebih dominan namun tidak ekstrem. Histogram panjang artikel terkonsentrasi di 100–400 kata dengan puncak di sekitar 200 kata dan long tail hingga 1.000 kata.



Boxplot panjang artikel menunjukkan kedua kelas memiliki median mirip (~230 kata) panjang artikel bukan pembeda utama clickbait. Headline clickbait sedikit lebih panjang (median 10 kata) vs non-clickbait (median 9 kata) dengan sebaran lebih lebar hingga 18 kata.




(Top 10 Kata Dominan per Kategori (Non-Clickbait vs Clickbait))

Non-clickbait didominasi kata formal dan institusional: 'indonesia' (>9.000), 'jakarta', 'kpk', 'pemerintah'. Clickbait menggunakan kata lebih umum dan populis: 'menjadi' (~5.000),


'tahun', 'orang', 'bisa'. Perbedaan kosakata ini menjadi sinyal kunci yang diekstrak model.

5.2 EDA Stance Detection


Dataset akhir: 300 artikel (Mendukung 59%, Membantah 41%). Statistik panjang teks: mean 433 kata, median 352 kata, max 2.389 kata (right-skewed). Rata-rata kata positif: 20.4, rata-rata kata negatif: 14.6.




Mendukung lebih dominan (59%) dengan imbalance ringan yang masih dalam batas wajar. Distribusi panjang teks right-skewed sebagian besar 200–600 kata dengan beberapa outlier hingga 2.389 kata.



Membantah cenderung lebih panjang dan variatif. 'Ahok' sangat dominan di kedua stance (topik-sentrik). Kemunculan 'tidak' dan 'bukan' menandakan banyak opini kontradiktif yang relevan untuk analisis stance.




Kata positif tidak membedakan stance secara signifikan (distribusi mirip antar kelas). Kata negatif lebih tinggi pada Membantah - menjadi indikator yang cukup kuat. Sentiment score: Mendukung cenderung lebih positif, Membantah lebih negatif dengan overlap yang cukup besar.




Heatmap menunjukkan sentiment_score berkorelasi positif kuat dengan pos_count dan negatif kuat dengan neg_count - sesuai formula. Korelasi sentiment_score terhadap label moderat, mengkonfirmasi perannya sebagai fitur pendukung yang relevan namun tidak deterministic.

5.3 EDA Hoax vs Valid


Dataset akhir: 1.042 artikel (Hoaks 61.7% = 644, Fakta 38.3% = 399). Rata-rata panjang: hoax 272 kata, valid 396 kata - selisih signifikan 46%. Statistik setelah filter: mean 321 kata, median 300 kata.



Dataset imbalanced dengan hoax 61.7% lebih dominan. Histogram terkonsentrasi di 50-500 kata dengan dua puncak di sekitar 240 dan 350 kata, mencerminkan dua kelompok karakteristik artikel.



Artikel valid memiliki median lebih tinggi (350-400 kata) vs hoax (200-250 kata) panjang artikel menjadi sinyal kredibilitas yang kuat. Headline valid lebih konsisten (median 10 kata), hoax lebih pendek (median 7 kata) namun variatif dengan outlier >20 kata.



'Klarifikasi' mendominasi VALID - fokus pada pembuktian fakta resmi dari institusi. 'Sumber', 'hoaks', 'media', 'foto' mendominasi

HOAX klaim asal-usul dan referensi visual. HOAX memiliki frekuensi kata lebih tinggi (~1.000) vs VALID (~900) pada top 10.

6. Feature Engineering

Fitur direkayasa berbeda per komponen sistem, disesuaikan dengan karakteristik data dan kebutuhan model masing-masing. Fitur-fitur ini dihasilkan selama proses data wrangling dan menjadi input resmi untuk tahap pemodelan oleh AI Engineer.

Fitur	Tipe	Dataset	Cara Hitung	Justifikasi
clean_text	string	Clickbait, Hoax, stance	headline + ' ' + article	Konteks penuh lebih informatif dari headline saja
article_len	int	Clickbait, Hoax, stance	len(full_text.split())	Digunakan filtering; valid 46% lebih panjang dari hoax
headline_len	int	Clickbait, Hoax	len(headline.split())	Sinyal tambahan; hoax median 7 kata vs valid 10 kata
clean_text	string	Stance	Normalisasi + stopword removal + Sastrawi stemming	Input teks model stance setelah pembersihan penuh
pos_count	int	Stance	$\sum \text{kata} \in \text{positif-indonesia.txt}$	Distribusi mirip antar stance fitur pendukung
neg_count	int	Stance	$\sum \text{kata} \in \text{negatif-indonesia.txt}$	Membantah lebih tinggi indikator kuat stance
sentiment_score	int	Stance	pos_count - neg_count	Mendukung lebih positif; Membantah lebih negatif

Catatan: Proses train-test split dilakukan oleh AI Engineer pada tahap modeling. Tabel berikut merangkum ukuran dataset final yang diserahkan DS ke AI Engineer.

Dataset	File Final	Total Data	Distribusi Kelas	Kolom Input
Clickbait	final_clickbait.csv	14.719	Non-cb=8.613 (58.5%), cb=6.106 (41.5%)	clean_text
Stance	final_data_stance.csv	300	Mendukung=177 (59%), Membantah=123 (41%)	clean_text + pos_count + neg_count + sentiment_score
Trusted Domain	final-pers.csv	875 media	Terverifikasi Dewan Pers	website (domain matching)
Hoax Scoring	final-data-hoax.csv	1.042	hoax=643 (61.7%), valid=399 (38.3%)	clean_text (referensi Cosine Similarity)

7. A/B Testing & Eksperimen

Eksperimen A/B Testing membandingkan dua skema pembersihan data (data cleaning) untuk menguji hipotesis signifikansi statistik terkait efisiensi waktu komputasi (Processing Latency) dan efektivitas pemangkasan kata tidak penting (Vocabulary Compression Rate) sebelum data diumpankan ke model Machine Learning.

- **Grup A - Control (Pembersihan Dasar):** Mengubah huruf menjadi kecil (lowercase), menghapus tanda baca standar, serta membuang spasi ganda.
- **Grup B - Variant (Pembersihan Lanjutan):** Normalisasi regex (hapus URL, mention @, hashtag, angka & simbol), formalisasi singkatan kata slang lokal, dan penyaringan stopwords (gabungan Sastrawi & kamus kustom).
- **Metode Uji Statistik:** Latency menggunakan Independent Two-Sample T-Test ($\alpha = 0.05$); Kepadatan Kata menggunakan Paired T-Test ($\alpha = 0.05$). Ukuran sampel: 500 dokumen.

Eksperimen dijalankan dengan sampel n=500 dokumen. Berikut hasil perbandingan kinerja kedua grup:

Metrik Evaluasi	Grup A - Control (Dasar)	Grup B - Variant (Lanjutan)	Delta
Ukuran Sampel Dokumen	500 dokumen	500 dokumen	Sama
Rata-rata Latency per Dokumen	0.0732 ms	0.1471 ms	+0.0740 ms (+101.1%)
Total Waktu Proses Seluruh Sampel	36.59 ms	73.57 ms	+36.99 ms
Total Kata Sebelum Cleaning	128.814 kata	128.814 kata	Sama
Total Kata Setelah Cleaning	128.814 kata	86.994 kata	-41.820 kata
Efisiensi Penyusutan Kata (%)	0.0%	32.5%	+32.5% (Ekstra Kompresi)

Rekomendasi Final - Gunakan Grup B (Variant / Pembersihan Lanjutan)

Meskipun Grup B membutuhkan waktu pemrosesan +101.1% lebih lama dibanding Grup A, dalam skala absolut perbedaan ini sangat kecil hanya selisih 0.0740 milidetik per berita, sehingga overhead komputasi ini sangat sepele untuk kebutuhan dashboard real-time.

Di sisi lain, Grup B secara signifikan memotong kata tidak penting sebesar 32.5% dibandingkan Grup A yang menghasilkan 0.0% penyusutan. Kompresi vocabulary ini menghilangkan noise bahasa non-faktual dan secara ilmiah akan melatih model Machine Learning yang lebih presisi, stabil, dan ringan. Oleh karena itu, pipeline preprocessing Grup B (Pembersihan Lanjutan) direkomendasikan sebagai skema final yang digunakan dalam sistem.

8. Dashboard Streamlit & Deployment

Dashboard interaktif dibangun menggunakan Streamlit untuk memvisualisasikan insight EDA seluruh dataset secara komprehensif. Dashboard telah di-deploy ke Streamlit Cloud dan dapat diakses publik.

Streamlit URL	https://headline-hoax-detector-team.streamlit.app/
----------------------	---

Dashboard memiliki 5 halaman navigasi yang masing-masing menyajikan analisis mendalam per komponen:

Halaman	Konten Utama
Overview	Project overview, problem statement, business questions, solusi yang dikembangkan, metodologi pipeline, output sistem
Clickbait Dataset	Info Dataset, Kamus Stopword, Preprocessing, Feature Engineering, EDA (distribusi label, panjang artikel/headline, top words), Data Dictionary
Stance Dataset	Info Dataset, Kamus Kata, Preprocessing, Feature Engineering, EDA (distribusi stance, panjang teks, top words, fitur sentimen, heatmap korelasi), Data Dictionary
Pers Dataset	Info Dataset, Preprocessing (filter berlapis), preview data final 875 media terverifikasi
Hoax Fact Dataset	Info Dataset, Kamus Stopword, Preprocessing, Feature Engineering, EDA (distribusi label, panjang artikel/headline, top words), Data Dictionary
A/B Testing	Eksperimen perbandingan Grup A (Pembersihan Dasar) vs Grup B (Pembersihan Lanjutan) Control Panel, Ringkasan & Rekomendasi, Visualisasi Distribusi, Detail Uji Statistik, Kamus Slang & Stopword

9. Kesimpulan & Rekomendasi

9.1 Kesimpulan

Proyek ini berhasil membangun pipeline NLP bertahap untuk menganalisis kredibilitas headline berita berbahasa Indonesia secara real-time. Tim Data Science telah menyelesaikan seluruh proses dari pengumpulan data, preprocessing empat dataset independen, EDA, hingga feature engineering yang siap digunakan untuk pemodelan.

Terkait deteksi clickbait (BQ1), EDA menunjukkan bahwa perbedaan paling signifikan antara clickbait dan non-clickbait terletak pada karakteristik kosakata non-clickbait menggunakan kata formal dan institusional sementara clickbait lebih umum dan populis. Panjang artikel tidak menjadi pembeda efektif karena selisih rata-rata keduanya hanya 17 kata.

Untuk analisis stance (BQ2), yang hanya berlaku bagi artikel non-clickbait, fitur `neg_count` terbukti menjadi indikator yang lebih kuat dibanding `pos_count` dalam membedakan Membantah dari Mendukung. Sentiment score berfungsi sebagai fitur pendukung dengan korelasi moderat terhadap label stance.

Verifikasi domain terpercaya (BQ3) ditangani melalui whitelist 875 media Siber yang terverifikasi penuh oleh Dewan Pers Indonesia. Pendekatan ini tidak bergantung pada model ML sehingga menjadi komponen paling reliabel dalam sistem.

Untuk hoax scoring (BQ4), EDA menunjukkan artikel valid rata-rata 46% lebih panjang dari hoax dan didominasi kata 'klarifikasi', sementara hoax banyak mengandung kata klaim asal-usul. Kondisi imbalance 61.7% hoax perlu diperhatikan dalam formula konversi skor Cosine Similarity.

9.2 Rekomendasi

Ke depan, terdapat beberapa aspek yang perlu ditingkatkan untuk memperkuat sistem. Dataset stance saat ini hanya mencakup satu topik (Ahok) sehingga model berpotensi tidak menggeneralisasi dengan baik ke isu lain. Perluasan dataset ke topik yang lebih beragam menjadi prioritas utama untuk mengurangi bias topik. Dari sisi kualitas preprocessing, kamus slang yang digunakan masih sangat terbatas (7–10 kata) dan belum mencakup variasi informal bahasa Indonesia secara menyeluruh. Penggunaan IndoBERT sebagai pretrained model juga layak dieksplorasi untuk meningkatkan pemahaman konteks semantik yang lebih dalam.

Selain itu, mengingat pola bahasa hoax dan clickbait terus berkembang, perlu diimplementasikan mekanisme re-training berkala. Formula konversi Cosine Similarity ke persentase hoax juga perlu dievaluasi ulang dengan mempertimbangkan imbalance dataset referensi (61.7% hoax) agar skor yang dihasilkan lebih proporsional.